

Explicação Dataset BAH

| Overview do dataset

O dataset conta com 300 participantes, cada participante foi gravado respondendo a 7 perguntas distintas. Cada vídeo é a resposta do participante a uma das perguntas. O foco do dataset é a detecção de ambivalência/hesitação nas respostas, as anotações foram feitas por especialistas a nível de frames e a tarefa final é a nível de vídeo.

Estrutura do dataset

| Pasta Videos

Contém os vídeos brutos por participante e por perguntas:

```
Videos/  
└─ 82557/  
    └─ Visite_1/  
        ├── 82557_Question_3_2024-08-22_14-48-26 Video.mp4  
        ├── 82557 Question 5 2024-08-22 14-48-26 Video.mp4  
        └─ 82557 Question 6 2024-08-22 14-48-26 Video.mp4
```

Pasta cropped-aligned-faces:

Contém os rostos dos participantes pré-cortados e alinhados, para cada frame:

```
Videos/  
└─ 82555/  
    └─ Visite_1/  
        └─ 82555_Question_3_2024-08-22_12-25-53_Video.mp4/  
            ├── frame-1.jpg  
            ├── frame-2.jpg  
            ├── frame-3.jpg  
            └─ frame-*.jpg
```

| Pasta transcription

Contém a transcrição de cada vídeo, tanto completa como por trechos com timestamps e detecção da língua. A transcrição foi feita com o modelo Whisper.

```
chunks:
- language: english
  text: ' I get a lot of joy doing things around the house, some DIY projects and
    overall just producing something that I can physically touch.'
  timestamp: !!python/tuple
    - 0.0
    - 12.0
- language: english
  text: ' In my job I make a lot of decisions but not a lot of concrete results.'
  timestamp: !!python/tuple
    - 12.0
    - 16.88
text: ' I get a lot of joy doing things around the house, some DIY projects and overall
  just producing something that I can physically touch. In my job I make a lot of
  decisions but not a lot of concrete results.'
```

| Pastas split, split-frames

COLOCAR AS PORCENTAGENS DOS SPLITS

Ambas as pastas possuem arquivos .txt que separam os participantes em treino, teste e validação.

Na pasta split cada linha dos arquivos .txt segue:

```
video_id, classe_do_video,transcrição_do_video_completa
```

Já na pasta split-frames cada linha segue:

```
frame_id, classe_do_frame
```

Em ambos os casos a classe é binária (1 para ambivalência, 0 para nada) e o identificador é o caminho para o vídeo (com o frame ao final para split-frames)

```
Videos/82813/Visite_1/82813_Question_3_2025-01-31_19-18-58_Video.mp4/frame-0.jpg
```

| Arquivos

- `extract_frames_from_videos.sh` e `extract_frames_from_videos.py`: servem para realizar a extração dos frames brutos de todos os vídeos, populando a pasta Frames.
- `bah-video.csv`: arquivo com todos os ids dos vídeos e sua respectiva classe.
- `BAH_Dataset_EULA-2.pdf`: End User Licence Agreement - EULA do dataset.
- `video_annotation_transcript.yaml`: possui informações detalhadas sobre as anotações do dataset, o arquivo é um dicionário python cuja chave é o id do vídeo e as seguintes informações:

- *all_cues*: pistas usadas (áudio, corpo, rosto, linguagem e inconsistências).
- *annotator_id*: ID do anotador.
- *certainty_ah*: confiança do anotador nas marcações.
- *fr_detailed_ah*: intervalo em frames com A/H.
- *frame_annotation*: rótulo por frame (1 = tem A/H, 0 = não tem).
- *global_ah*: rótulo geral do vídeo (1/0).
- *time_detailed_ah*: intervalo em tempo com A/H.
- *transcript*: fala segmentada + transcrição completa (text).

Segue um exemplo do arquivo no próximo slide.

```
Videos/82553/Visite_1/82553_Question_1_2024-08-22_12-11-55_Video.mp4:
  all_cues:
    - audio: null
      body: null
      facial: null
      inconsistencias: null
      language: null
    - audio: null
      body: null
      facial: null
      inconsistencias: null
      language: null
  annotator_id: MGG
  certainty_ah:
    - 1
  fr_detailed_ah:
    - - 51
      - 95
  frame_annotation:
    - - Videos/82553/Visite_1/82553_Question_1_2024-08-22_12-11-55_Video.mp4/frame-0.jpg
      - 0
    - - Videos/82553/Visite_1/82553_Question_1_2024-08-22_12-11-55_Video.mp4/frame-1.jpg
      - 0
```

| Meta data

- `meta_data.yml` consiste em um dicionário com 1 entrada por participante com os seguintes dados:

- idade e faixa etária
- país de nascimento
- província do Canadá onde mora
- etnia e etnia simplificada
- gênero
- se é estudante
- permissão de uso em publicações
- permissão de uso em desafios (challenges)

- Exemplo arquivo de metadata:

```
'82553':  
  Age: 51  
  Age range: 45 - 54 years  
  Birth country: Canada  
  Canada province: Ontario (ON)  
  Ethnicity: East Asian (Chinese, Korean, Japanese, and/or Taiwanese descent)  
  Ethnicity simplified: Asian  
  Gender: Male  
  Is student: 'No'  
  Use in challenges: 'Yes'  
  Use in publications: 'Yes'
```

Para carregar os arquivos .yaml do dataset os autores recomendam instalar PyYAML (pip install pyyaml) e usar:

```
import yaml

with open('meta_data.yaml', 'r') as f:
    content = yaml.safe_load(f)
    # ou:
    content = yaml.full_load(f)
```